

Ade Tirta Rahmat Hidayat – 1103203212 – Analisis MLP Regresi

1. Modifikasi Arsitektur MLP untuk Underfitting

Jika model MLP dengan tiga hidden layer (256-128-64) menghasilkan underfitting pada dataset, beberapa langkah yang dapat diambil adalah:

- Menambah jumlah unit pada hidden layer
Model underfitting mungkin disebabkan oleh kapasitas model yang terlalu kecil untuk menangkap pola dalam data. Menambah jumlah neuron pada layer tersembunyi (misalnya 512-256-128 atau lebih) dapat meningkatkan kapasitas model untuk mempelajari pola lebih kompleks.
- Menambah jumlah hidden layer
Arsitektur yang terlalu sederhana mungkin tidak cukup untuk menangkap hubungan yang lebih rumit dalam data. Menambah lebih banyak hidden layer (misalnya menjadi 4 atau 5 layer) dapat membantu model dalam menangkap representasi yang lebih kompleks.
- Menggunakan fungsi aktivasi non-linear yang lebih kuat
Selain ReLU, fungsi aktivasi seperti Swish atau GELU dapat dicoba untuk mendapatkan performa yang lebih baik pada beberapa jenis masalah.

2. Alasan Perubahan Berdasarkan Bias-Variance Tradeoff

Underfitting berarti model memiliki bias tinggi, yaitu terlalu sederhana untuk menangkap pola dalam data. Dengan meningkatkan kapasitas model, baik dari segi jumlah neuron, layer, atau mengurangi regularisasi, kapasitas model untuk menangkap pola menjadi lebih baik, yang mengurangi bias dan meningkatkan performa. Namun, hal ini dapat meningkatkan varians, yang perlu dipantau untuk menghindari overfitting.

3. Alternatif Loss Function Selain MSE

Selain Mean Squared Error (MSE), beberapa loss function lain yang dapat digunakan untuk regresi adalah:

- Mean Absolute Error (MAE):
Kelebihan MAE yaitu lebih tahan terhadap outlier karena tidak memberikan hukuman besar untuk kesalahan besar (berbeda dengan MSE yang menggunakan kuadrat kesalahan). Kekurangan MAE yaitu tidak memberikan gradien yang halus seperti MSE, sehingga optimisasi model bisa lebih sulit.
- Huber Loss:
Kelebihannya yaitu merupakan kombinasi dari MSE dan MAE, di mana kesalahan kecil dihitung dengan kuadrat (seperti MSE) dan kesalahan besar dihitung dengan nilai absolut (seperti MAE). Ini mengurangi sensitifitas terhadap outlier. Kekurangannya yaitu memerlukan parameter tambahan untuk threshold, dan mungkin lebih sulit untuk dioptimalkan dibandingkan MSE.
- Quantile Loss (untuk regresi kuantil):
Kelebihan: Berguna saat ingin memprediksi kuantil tertentu dari distribusi target, bukan hanya nilai rata-rata. Kekurangan: Tidak meminimalkan kesalahan secara keseluruhan, tetapi lebih fokus pada kesalahan pada kuantil tertentu.

4. Dampak Rentang Nilai Fitur terhadap Pelatihan MLP

Jika satu fitur memiliki rentang nilai 0-1 dan fitur lainnya memiliki rentang 100-1000, hal ini akan mempengaruhi pelatihan model MLP karena:

- Skala fitur yang berbeda
Fitur dengan rentang lebih besar akan memiliki gradien yang lebih besar dibandingkan dengan fitur dengan rentang lebih kecil. Ini menyebabkan model sulit untuk belajar secara efektif, dengan gradien yang tidak seimbang.

- Pengaruh pada pembaruan bobot
Update bobot selama pelatihan akan lebih dipengaruhi oleh fitur dengan rentang yang lebih besar, sementara fitur dengan rentang lebih kecil akan berkontribusi lebih sedikit terhadap pembaruan bobot. Ini menyebabkan pembelajaran menjadi tidak seimbang.

Solusi:

- Normalisasi atau standarisasi
Fitur perlu dinormalisasi atau distandarisasi agar mereka memiliki rentang yang serupa, yang memastikan gradien dihitung secara konsisten.
5. Mengukur Kontribusi Relatif Fitur Tanpa Nama Fitur
- Beberapa metode yang dapat digunakan untuk mengukur kontribusi relatif setiap fitur terhadap prediksi model adalah:
- Permutation Importance:
Setelah model dilatih, nilai fitur dipermutasi secara acak dan pengaruhnya terhadap performa model diukur. Fitur yang paling penting akan menyebabkan penurunan performa terbesar saat dipermutasi.
 - Weight Analysis (untuk model linear atau MLP):
Jika menggunakan model MLP, analisis bobot yang terhubung ke setiap fitur di layer pertama dapat memberikan indikasi kontribusi fitur terhadap prediksi.
 - SHAP (Shapley Additive Explanations):
Metode: SHAP memberikan kontribusi setiap fitur terhadap prediksi untuk setiap instance dalam data, meskipun model sangat kompleks.
6. Desain Eksperimen untuk Memilih Learning Rate dan Batch Size
- Untuk memilih learning rate dan batch size secara optimal, eksperimen berikut dapat dilakukan:
- Eksperimen Learning Rate:
Mulai dengan learning rate kecil (misalnya 0.001) dan lakukan grid search atau random search di sekitar rentang (misalnya 0.0001 hingga 0.1). Alternatif lainnya adalah menggunakan learning rate scheduler untuk menyesuaikan learning rate selama pelatihan.
Analisis Tradeoff:
Learning rate yang terlalu kecil akan memperlambat pelatihan, sedangkan yang terlalu besar dapat menyebabkan ketidakstabilan. Learning rate scheduler membantu mengatasi ini dengan menurunkan learning rate setelah beberapa epoch.
 - Eksperimen Batch Size:
Cobalah berbagai ukuran batch (misalnya 16, 32, 64, 128) dan ukur waktu pelatihan serta performa model pada data validasi.
Analisis Tradeoff:
Ukuran batch yang lebih besar mempercepat pelatihan tetapi membutuhkan lebih banyak memori dan bisa membuat model stagnan dalam optimisasi. Ukuran batch yang lebih kecil memberikan lebih banyak variasi dalam pembaruan bobot, tetapi lebih lambat dalam konvergensi.